

용접선 검출 인공지능 학습 모델 개발



저자1 201924576 정재빈

저자2 201924461 류태욱

저자3 201924443 김주언

지도교수 김원석

목 차

1. 서론	1
1.1 연구 배경	1
1.2 기존 문제점	1
1.3 연구 목표	1
2. 연구 구성	2
2.1 Unity와 학습 데이터	2
2.2 YOLO 와 Line Detection을 이용한 용접선 검출	2
3. 연구 내용	2
3.1 Unity를 이용한 3D 모델 제작	2
3.2 Labeling 자동화 작업	4
3.3 Unity 모델 고도화	6
3.4 모델 생성 UI	11
3.5 용접장 인식 YOLO 모델	13
4. 연구 결과 분석 및 평가	15
5. 결론 및 향후 연구 방향	15
6. 구성원별 역할 및 개발 일정	16
7. 참고 문헌	17

1. 서론

1.1 연구 배경

조선업 및 철강 산업에서 구조물의 부재 간 용접 작업은 매우 중요한 공정으로, 작업의 정확성과 효율성이 생산성에 큰 영향을 미친다. 특히, 대형 구조물의 경우 용접해야 할 부위와 길이를 정확하게 파악하는 것이 필수적이다. 최근에는 이러한 용접 작업의 자동화를 위해 딥러닝을 활용한 다양한 연구가 진행되고 있으며, 이를 통해 현장의 작업 효율성을 높이고, 인적 오류를 최소화하려는 시도가 이루어지고 있다. 본 연구는 딥러닝 모델을 활용하여 용접 부위의 길이를 자동으로 검출하고, 이를 AI를 통해 학습시킴으로써 용접 작업의 효율성을 극대화하는 것을 목표로 한다. 특히, Unity 기반의 가상 환경을 활용하여 학습 데이터를 증강하고, 실세계의 데이터를 보완함으로써 모델의 성능을 극대화하려는 시도를 포함하고 있다.

1.2 기존 문제점

기존의 용접 작업에서는 주로 작업자의 경험과 눈으로 용접할 부위를 파악하고 작업을 수행하는 경우가 많다. 이러한 방식은 작업자의 숙련도에 따라 품질이 달라질 수 있으며, 부정확한 용접으로 인한 품질 저하 또는 시간 소모가 발생할 수 있다. 또한, 기존 딥러닝 모델을 활용한 자동화 작업에서도 2D 이미지 기반의 접근 방식이 주를 이루었기 때문에, 3D 정보가 충분히 반영되지 않아 복잡한 구조물에 대한 정확한 인식이 어려웠다.

특히, 용접 부위의 정확한 길이를 계산하는 데 있어 2D 이미지 데이터만으로는 한계가 있었으며, 3D 데이터를 활용한 접근이 필요하다는 요구가 있었다. 이에 따라 Depth 카메라를 활용한 3D 포인트 클라우드 데이터를 사용하고자 하였으나, 기존 시스템에서는 해당 데이터를 효과적으로 처리하지 못하는 한계가 있었다.

1.3 연구 목표

본 연구의 목표는 딥러닝 모델을 활용하여 셀 내부의 부재 간 용접 부위와 그 길이를 자동으로 인식하고, 이를 검출하는 시스템을 구축하는 것이다. 이를 위해 Depth 카메라를 사용하여 3D 포인트 클라우드 데이터를 수집하고, Unity 기반의 가상 환경에서 다양한 학습 데이터를 증강하여 딥러닝 모델의 성능을 높이는 작업을 진행하였다. 최종적으로는 YOLO와 Line Detection 모델을 결합하여 용접선과 그 길이를 정확하게 추출하고, 이를 기반으로 한 자동화된 용접 검출 시스템을 개발하는 것이 연구의 궁극적인 목표이다.

2. 연구 구성

2.1 Unity와 학습 데이터

Unity는 가상 환경에서 다양한 물리적 요소를 반영할 수 있는 강력한 도구로, 빛, 그림자, 재질 등의 환경 설정을 통해 현실적인 이미지 데이터를 생성할 수 있다. 이러한 가상 데이터를 학습에 활용하면, 모델이 더 다양한 조건에서 데이터를 학습하게 되어 성능 향상에 기여할 수 있다. 특히, 다양한 형태의 부재와 조명 조건 등을 무작위로 조합하여 대량의 학습 데이터를 빠르게 생성할 수 있다는 장점이 있다.

Unity를 활용한 데이터 증강은, 단순히 이미지를 생성하는 것에서 그치지 않고, 다양한 각도와 조명 조건을 적용하여 모델이 여러 시나리오에서 학습할 수 있도록 돕는다. 예를 들어, 낮과 밤의 조명 차이, 그림자의 방향, 물체의 반사 특성 등을 가상 환경에서 시뮬레이션할 수 있어, 실제 현장에서 발생할 수 있는 다양한 변수들을 학습 데이터에 포함할 수 있었다. 이러한 방식은 AI 모델이 실제 환경에서 더 나은 성능을 발휘할 수 있도록 돕는 중요한 역할을 한다.

2.2 YOLO 와 Line Detection을 이용한 용접선 검출

YOLO 모델은 객체 탐지 분야에서 실시간으로 우수한 성능을 발휘하는 딥러닝 모델로, 고속 처리 능력을 갖추고 있어 용접 작업의 효율성을 극대화하는 데 적합하다. YOLO 모델은 이미지 내의 여러 객체를 동시에 탐지하고, 객체의 위치와 크기를 빠르게 파악할 수 있다는 장점이 있다.

그러나, 용접선은 일반적인 객체와 달리 직선 형태의 특징을 가지기 때문에, YOLO 모델만으로는 용접선을 정확하게 추출하기 어려운 문제가 있었다. 이를 보완하기 위해 **Line Detection** 알고리즘을 추가로 도입하여, 용접선의 길이와 위치를 더 정밀하게 계산할 수 있도록 하였다. Line Detection 알고리즘은 이미지에서 직선을 인식하고, 이를 기반으로 용접해야 할 부위의 길이를 정확하게 검출할 수 있다.

3. 연구 내용

3.1 Unity를 이용한 3D 모델 제작

실제 용접 작업장의 환경을 최대한 사실적으로 재현하기 위해 Unity를 활용하여 다양한 형태의 T 및 L자 론지(Longi), 칼라플레이트, 슬롯홀을 조합한 3D 모델을 제작하였다. 이러한 3D 모델링은 현실 세계에서의 작업 환경과 유사한 구조로 설계되었으며, 용접 부위에서 발생하는 다양한 물리적 특성을 반영하도록 고안되었다. 특히, 각종 부품이 결합할 때 발생할 수 있는 시각적 차이점(예: 재료의 표면 텍스처,

조명에 따른 반사 및 그림자 등)을 고려하여 총 26종의 다양한 모델이 제작되었다.




그림 1. 칼라플레이트




그림 2. 론지

다음 그림 1, 그림 2 와 같은 형태로 모델링을 진행하고, 이를 Unity에서 무작위 조합으로 그림 3과 같이, 실제 용접장과 유사한 형태의 이미지가 나올 수 있도록 하였다.

모델링 과정에서는 T자 및 L자 형상의 론지와 칼라플레이트, 그리고 다양한 크기의 슬롯홀을 무작위로 조합하여 여러 가지 환경을 구성할 수 있도록 설정되었다. 이를 통해 AI 모델이 실제 용접 현장에서 발생할 수 있는 여러 상황을 학습할 수 있게끔 데이터를 생성할 수 있었다. 각 부품은 Unity에서 무작위로 배치되고 조합되었으며, 그림 3과 같이 조합된 형태의 3D 이미지들이 AI 모델 학습용으로 자동 생성되었다.



그림 3. 무작위 조합으로 만들어진 모델

이러한 작업을 통해 AI 학습을 위한 대규모 자동 학습 데이터 생성이 가능해졌다. 특히, 다양한 상황에서 조명과 배경이 어떻게 각 부품의 인식에 영향을 미치는지를 분석할 수 있게 되어, 향후 더 정교한 데이터 증강과 학습이 가능하도록 기반을 마련했다.

이 모델을 통해 YOLOv8과 같은 인공지능 모델이 실제 용접 환경에서 일어날 수 있는 다양한 변수를 학습하고, 이를 활용하여 더 정확한 인식과 예측이 가능하게 하였다.

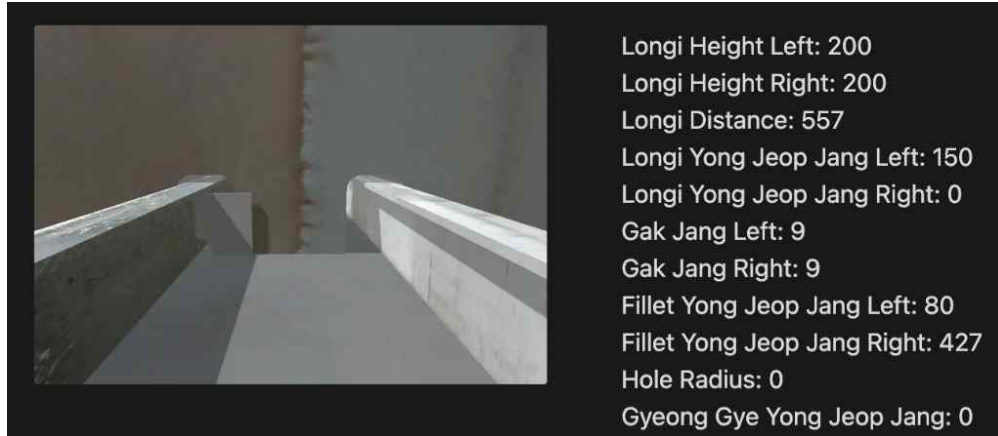


그림 4. 각 모델링 별 라벨링 데이터

또한, 이번 작업에서는 단순히 3D 모델을 제작하는 것에서 그치지 않고, 각 모델에 대한 자동 라벨링 시스템을 구축하여 AI 학습을 더욱 효율적으로 수행할 수 있도록 하였다. 무작위로 생성된 모델마다 다양한 파라미터들이 자동으로 라벨링 되었으며, 이를 통해 각 모델의 고유한 속성들이 정확하게 기록되고 저장되었다. 예를 들어, 론지의 높이, 각도, 슬롯홀의 위치 및 크기, 칼라플레이트의 부착 여부와 같은 상세한 정보를 자동으로 추출하여 텍스트 형태로 저장하였다.

이 과정은 사람이 일일이 라벨링 작업을 수행하는 수동적인 방식에서 벗어나, 데이터 수집과 라벨링이 동시에 이루어질 수 있는 효율적인 시스템을 제공했다. 이를 통해 대규모의 학습 데이터를 빠르게 확보할 수 있었으며, 학습 과정에서 발생할 수 있는 오류를 최소화하였다.

3.2 Labeling 자동화 작업

본 과제의 주요 목표 중 하나는 용접장에서 발생하는 다양한 변수, 예를 들어 론지의 높이, 론지 사이의 거리 등을 추출하고 이를 AI 모델이 학습할 수 있는 형태로 변환하는 것이었다. 초기 단계에서는 이러한 변수를 추출하기 위해 **Line Detection** 모델을 사용하는 방안을 검토하였다. 하지만, 이 과정에서 실제 모델이 정확하게 적용되지 않거나, 모델의 한계로 인해 불필요한 선이 감지되는 문제가 발생하였다. 특히, 용접장의 복잡한 환경에서는 단순한 선 감지로는 필요한 데이터를 정확하게 추출하는 데 어려움이 있었다.

이러한 문제를 해결하기 위해, 처음에는 **Segmentation** 모델을 활용한 새로운 방식을 도입하였다. Segmentation 모델은 이미지 내에서 각 객체의 경계를 더욱 정확하게 인식할 수 있도록 해주며, 이를 통해 용접 작업에서 필요한 주요 정보들을 추출할

수 있었다. 이를 위해 실제 모델을 **Masking**처리하고, 객체별로 고유한 색상을 부여하여 이미지 내에서 서로 다른 객체들을 구분할 수 있도록 하였다.

다음으로, Unity 상에서 Masking 작업을 통해 객체들이 시각적으로 잘 구분되도록 설정한 후, **cv2 라이브러리**를 활용하여 Masking 된 이미지를 분석하였다. 각 객체에 매핑된 색상을 기반으로 객체의 경계 상자(바운딩 박스)를 추출하고, 이를 **YOLO 형식**으로 변환하여 라벨링 작업을 자동으로 수행하였다. 이 과정에서 각 객체의 위치, 크기, 중심 좌표 등의 정보를 YOLO 모델 학습에 적합한 형식으로 저장할 수 있었다.




그림 5. 원본 이미지




그림 6. 마스킹한 이미지

위의 **그림 5**와 **그림 6**에서 볼 수 있듯이, Unity 상에서 모델을 Masking한 후 각 모델에 고유한 색상을 부여하였다. 이후 스크린샷을 저장하고, 이를 **cv2**를 통해 처리하여 각 객체의 경계를 탐지하고 라벨링 데이터를 추출하였다. 이 과정을 통해 YOLO 학습에 필요한 정확한 데이터를 효과적으로 생성할 수 있었다.

라벨링 된 데이터는 아래 **그림 7**과 같이 YOLO 학습 형식에 맞추어 정규화된 좌표값과 함께 저장되었으며, 이는 AI 모델이 객체를 인식하고 분류하는 데 중요한 학습 데이터로 활용되었다. 이 자동화된 라벨링 작업을 통해 대규모 데이터를 효율적으로 생성할 수 있었으며, 수동으로 처리할 때 발생할 수 있는 오류를 최소화하고, 더 빠르고 정확한 학습 데이터 구축이 가능해졌다.

```
0 0.69375 0.6421875 0.034375 0.059375
1 0.46015625 0.6609375 0.3171875 0.015625
2 0.29453125 0.553125 0.0171875 0.225
2 0.71171875 0.5109375 0.0140625 0.19375
6 0.66484375 0.5421875 0.0921875 0.25625
```

그림 7. 추출한 yolo 학습용 label 데이터

하지만, Segmentation 작업을 진행한 이후, 초기 결과 데이터를 분석한 결과 실제

용접장의 론지(Longi)의 높이나 거리와 같은 정보들을 정확하게 추출하기 어렵다는 피드백을 받았다. 이러한 문제는 Segmentation 모델이 단순히 물체의 경계를 인식하고 그 위치를 파악하는 데는 유용하지만, 실질적인 깊이 정보나 부재 간의 거리를 정확하게 파악하는 데 한계가 있기 때문이다. 따라서 우리는 더 정밀한 데이터를 확보하고, 용접 부위에 대한 깊이와 거리 정보를 개선할 필요가 있었다.

이를 해결하기 위해, 필요한 데이터로 슬롯홀(Slot Hole), 플레이트(Plate), 론지 용접 부위와 같은 주요 부재들을 마스킹(Masking) 처리하는 방식으로 접근을 변경하였다. 이를 통해, 모델이 각 부재의 위치뿐만 아니라 높이, 거리 등의 중요한 물리적 정보를 더욱 명확하게 인식할 수 있도록 하였다.



그림 8. 원본 이미지




그림 9. 마스킹한 이미지

그래서 마스킹 처리를 통해, 각 부재를 명확하게 구분하고, 용접 부위의 높이나 길이를 더욱 직관적으로 표현할 수 있도록 하였다. 이러한 마스킹 작업을 통해 부재 간의 위치와 거리를 명확하게 확인할 수 있었고, 이를 바탕으로 더 정밀한 용접선 검출이 가능해졌다.

특히, 이전과 달리 단순히 텍스처만 변경하는 방식으로는 용접 부위의 위치를 제대로 마스킹할 수 없었기 때문에, 더 세밀한 마스킹 처리가 필요했다. 그 결과, 각 용접 부위의 위치를 $1 \times 1 \times 1$ 박스로 세밀하게 구분하여 높이나 길이 같은 정보가 왜곡되지 않도록 처리하였다.

3.3 Unity 모델 고도화

깊이 스텐실 버퍼

용접장 셀(Cell)의 론지 주변으로 나 있는 슬롯 홀을 구현하기 위해, 슬롯 홀 규격과 일치하는 오브젝트를 만들고 깊이 스텐실 버퍼를 조절하여 슬롯 홀 오브젝트가 있는 부분을 렌더링에서 제외하는 방식으로 구멍을 구현하였다.

깊이 스텐실 버퍼는 그래픽 렌더러에서 해당 픽셀을 화면에 그릴지 말지를 결정하는 버퍼이다.



그림 10. 깊이 스텐실 버퍼를 이용한 슬롯 홀




그림 11. 스텐실 버퍼의 원리

그림자 상호작용이 가능한 셰이더에 대한 연구

HLSL 코드를 작성하여 그림자의 선명도를 조절할 수 있는 전용 셰이더 제작을 시도하였다.




그림 12. 그림자 셰이더 제작 시도

그림자를 연산하여 표시하는 중 깨진 그림자가 표시되는 문제, Unity의 Directional Light/Additional Light/Lightmap/Light probe 등 조명 설정에 따라 완전히 달라지는 렌더링 방식, 그리고 Directional Light 이외의 경우 어떻게 Lighting을 수행하는지에 대한 정보 부재로 인해 불가피하게 외부 그림자 에셋을 사용하게 되었다

이후, 실제 현장 사진과 최대한 유사한 학습 데이터, 또는 극단적인 상황의 데이터를 생성할 수 있도록, 다음과 같은 요소를 0~100단계로, 팩터로 만들어 조절할 수 있도록 하였다.

텍스처 노이즈 팩터

실제 용접 작업 중에는 표면의 마모나 손상, 환경적 요인에 따라 금속의 표면 질감이 다르게 나타날 수 있다. 이를 반영하기 위해, 텍스처의 노말(잡음)을 조절하여 금속 표면의 거친 정도와 반사 특성을 시뮬레이션했다.

이 팩터는 작업 환경이나 시간의 경과에 따라 금속 표면에 발생할 수 있는 미세한 손상을 표현한다. 0단계에서는 매우 매끄럽고 깨끗한 표면을 나타내며, 100단계에서는 심각하게 마모되고 손상된 텍스처를 보여준다. AI 모델은 이를 학습함으로써, 표면의 질감에 따라 다른 결과를 예측할 수 있다.



그림 13. 텍스처 노이즈 팩터가 0인 상태와 100인 상태

녹 팩터

실제 상황에서는 각 셀마다, 부재마다 외부 노출 등의 요인에 따라 금속 표면에 녹이 있을 수 있다. 이를 Detailed Base Map, Detailed Albedo Map을 통해 텍스처의 녹슨 자국을 증폭시키거나 생성하는 팩터를 만들었다.

0단계는 일반적인 정도의 녹 또는 얼룩을, 100단계는 매우 심한 녹과 얼룩을 나타낸다. 해당 팩터도 텍스처 노이즈 팩터와 같이 표면의 질감에 따라 다른 결과를 예측하게 하는 역할을 한다.



그림 14. 녹 팩터가 0인 상태와 100인 상태

스크래치 팩터

용접 부위에는 물리적 마찰이나 충돌로 인한 스크래치가 발생할 수 있으며, 이는 용접 작업의 품질에 영향을 줄 수 있다. Detailed Normal Map을 통해 스크래치를 텍스처에 적용하여 현실감을 더했다.

0단계는 스크래치가 거의 없는 깨끗한 표면을, 100단계는 다양한 방향으로 깊게 긁힌 스크래치를 나타낸다. 이러한 팩터를 도입함으로써, 모델이 스크래치로 인해 발생하는 시각적 변화를 학습할 수 있게 된다. 이는 특히 용접 품질 검증이나 결함 탐지와 같은 작업에서 중요한 역할을 한다.




그림 15. 스크래치 팩터가 0인 상태와 100인 상태

조명 팩터

조명은 용접 작업에서 매우 중요한 요소이다. 조명의 밝기나 각도에 따라 금속 표면의 반사 특성과 그림자의 위치가 달라지며, 이는 AI가 용접 부위를 정확하게 인식하는 데 영향을 줄 수 있다.

이 팩터는 메인 조명의 밝기와 각도를 조절하여, 다양한 조명 조건에서 모델이 학습할 수 있도록 돕는다. 0단계에서는 매우 어두운 환경을, 100단계에서는 매우 밝은 환경을 나타낸다. 이를 통해 AI 모델이 조명 조건에 상관없이 안정적으로 객체를 인식할 수 있도록 훈련된다.



그림 16. 조명 팩터가 0인 상태와 100인 상태

조도 노이즈 팩터

용접 작업 중에는 빛이 직접적으로 용접 부위에 닿지 않거나, 복잡한 환경으로 인해 조명이 불규칙하게 반사되는 경우가 많다. 조도 노이즈를 조절하여 이러한 비정상적인 조명 상황을 시뮬레이션하였다.

이 팩터는 용접 작업 중 발생할 수 있는 다양한 불규칙한 빛 반사와 노이즈를 반영한다. 0단계에서는 일반적 상황보다 낮은 밝기의 용접광 빛이 보이는 조건을 재현하며, 100단계에서는 매우 밝은 용접광이 다른 부재를 가리는 조건을 재현하여, 모델이 그러한 환경에서도 정상적으로 객체를 탐지할 수 있도록 훈련된다.



그림 17. 조도 노이즈 팩터가 0인 상태와 100인 상태

그림자 팩터

그림자는 용접 작업에서 중요한 시각적 신호를 제공하는 요소이다. 그림자가 너무 짙으면 용접 부위가 잘 보이지 않거나, 반대로 너무 얇으면 경계가 불분명할 수 있다. 그림자의 선명도와 강도를 조절하여 다양한 상황에서 그림자가 용접 부위에 미치는 영향을 학습할 수 있도록 하였다.

이 팩터는 그림자의 선명도와 강도를 조절하며, 0단계에서는 매우 선명하고 짙은 그림자를, 100단계에서는 매우 부드럽고 옅은 그림자를 나타낸다. YOLOv8 모델이 그림자의 유무와 강도에 상관없이 용접 부위를 인식할 수 있도록 훈련하기 위한 중요한 팩터이다.




그림 18. 그림자 팩터가 0인 상태와 100인 상태

3.4 모델 생성 UI

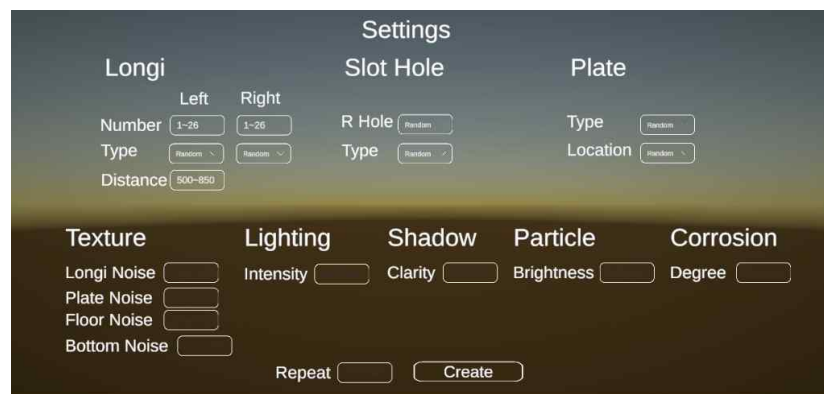


그림 19. 모델 생성 UI

이번 연구에서는 다양한 파라미터를 조정하여 모델을 생성할 수 있는 UI를 개발하였다. 이 UI는 사용자가 다양한 조건과 변수에 맞추어 론지(Longi), 슬롯홀(Slot Hole), 플레이트(Plate) 등을 포함한 용접 모델을 생성할 수 있도록 설계되었다.

UI 구조는 크게 론지(Longi), 슬롯홀(Slot Hole), 플레이트(Plate), 텍스처(Texture), 조명(Lighting), 그림자(Shadow), 파티클(Particle), 부식(Corrosion)의 8가지 주요 섹션으로 나뉘어 있다. 이 섹션을 통해 사용자는 각 파라미터를 조정하여 용접 작업에서 발생할 수 있는 다양한 상황을 가상으로 구현할 수 있으며, 이를 통해 학습 데이터를 자동으로 생성할 수 있다.

1. 론지(Longi) 섹션

Number: 론지의 개수를 왼쪽과 오른쪽 각각 조정할 수 있다. 사용자는 론지의 개수를 1에서 26까지 조정 가능하다.

Type: 론지의 종류를 설정할 수 있으며, 사용자가 선택하거나 무작위(Random)로 선택되도록 설정할 수 있다.

Distance: 론지 사이의 거리를 500에서 850까지 세밀하게 조정하여 부재 간 용접 부위의 거리를 설정할 수 있다.

2. 슬롯홀(Slot Hole) 섹션

R Hole: 슬롯홀의 반지름 크기를 설정할 수 있는 파라미터로, 사용자는 다양한 크기의 슬롯홀을 선택할 수 있다.

Type: 슬롯홀의 타입을 사용자가 선택하거나 무작위(Random)로 설정하여 다양한 형태의 슬롯홀을 모델에 반영할 수 있다.

3. 플레이트(Plate) 섹션

Type: 플레이트의 종류를 설정할 수 있는 섹션이다. 사용자가 직접 선택할 수 있으며, 무작위(Random)로도 설정할 수 있다.

Location: 플레이트의 위치를 설정할 수 있으며, 사용자가 설정한 위치에 따라 다양한 시뮬레이션이 가능하다.

4. 텍스처(Texture) 섹션

Longi Noise: 론지의 표면 노이즈 강도를 조절할 수 있으며, 노이즈의 강도에 따라 론지의 표면 상태를 시뮬레이션할 수 있다.

Plate Noise: 플레이트의 표면 노이즈 강도를 설정하여 플레이트 표면의 거칠기나 마모 상태를 조절할 수 있다.

Floor Noise: 작업 환경의 바닥 텍스처 노이즈 강도를 조정하여, 작업 환경의 상태를 반영한 데이터를 생성할 수 있다.

Bottom Noise: 바닥 하부의 노이즈를 조정하는 섹션으로, 세부적인 환경 변수를 반영하여 더욱 현실적인 시뮬레이션을 가능하게 한다.

5. 조명(Lighting) 섹션

Intensity: 조명의 밝기를 조절하는 파라미터로, 용접 환경에서 발생할 수 있는 다양한 조명 조건을 반영할 수 있다.

6. 그림자(Shadow) 섹션

Clarity: 그림자의 선명도를 설정할 수 있는 섹션이다. 선명한 그림자와 흐릿한 그림자 등 다양한 그림자 조건을 반영한 데이터 생성이 가능하다.

7. 파티클(Particle) 섹션

Brightness: 작업 환경에서 발생할 수 있는 먼지나 입자 같은 파티클의 밝기를 조절하는 파라미터로, 용접 과정 중 발생할 수 있는 시각적 요소를 반영한다.

8. 부식(Corrosion) 섹션

Degree: 금속 부식의 정도를 조절할 수 있는 섹션으로, 부식이 없는 깨끗한 표면부터 심각하게 부식된 표면까지 다양한 부식 상태를 시뮬레이션할 수 있다.

하단의 컨트롤 섹션에서는 Repeat와 Create 버튼을 제공하여, 설정된 파라미터를 기반으로 모델을 반복 생성하거나, 단일 모델을 생성할 수 있다. 이 UI를 통해 사용자는 다양한 파라미터를 조정하여 용접 부위에 대한 학습 데이터를 자동으로 생성할 수

있으며, 이를 통해 더욱 효율적이고 다양한 학습 시나리오를 제공할 수 있다.

3.5 용접장 인식 YOLO 모델

이번 연구에서는 YOLO 모델의 성능을 파라미터별로 분석하여, 이미지 결과를 확인하고자 하였다. 실제 현장의 사진을 라벨링 하여 20:1 비율로 학습에 포함한 경우, 모델은 비교적 높은 인식률을 보였다. 실제 이미지와 유사한 조건에서 모델을 훈련했기 때문에, YOLO 모델이 용접 부위와 부재 간의 관계를 잘 인식할 수 있었다.

그러나 교수님께서 지적하신 바와 같이, 연구의 목표는 최대한 현실에 가까운 시뮬레이션 환경을 구성하고, 다양한 변수와 학습 데이터를 반영하여 실제 현장에서의 정확한 용접선 인식을 달성하는 것이었다. 이를 위해 여러 가지 환경적 변수(예: 조명, 텍스처 노이즈, 부재의 마모 상태 등)를 추가하여 변화를 주고, 모델을 다양한 조건에서 학습시켜 모델의 성능에 미치는 영향을 분석하였다.

YOLO 모델의 성능을 더욱 구체적으로 평가하기 위해, 텍스처 노이즈, 조명, 조명 노이즈(용접광), 스크래치 노이즈, 부식 팩터를 각기 다른 강도로 조정하여 총 16개의 학습 모델을 생성하고 실험을 진행했다. 파라미터별로 모델을 세분화하여 학습한 결과는 다음과 같다:

1. 텍스처 노이즈 팩터 0%, 50%, 100%

텍스처 노이즈가 0%일 때 모델은 상대적으로 매끄러운 표면에서 정확하게 용접 부위를 인식하였으나, 50%와 100%로 증가할수록 표면의 거칠기로 인해 인식률이 점차 저하되었다. 특히 노이즈가 심해질수록 경계를 흐리게 만들어, 부재 간의 관계를 파악하는 데 혼란을 주었다.

2. 조명 팩터 0%, 50%, 100%

일반 조명 조건에서는 조명이 강할수록 용접 부위의 반사율이 커지면서 인식이 어려워졌다. 조명이 적절한 수준에서 유지된 0%에서는 모델이 비교적 높은 성능을 보였으나, 조명 강도가 50%와 100%로 증가할수록 부재 경계를 정확히 파악하지 못하는 결과가 나타났다.

3. 조명 노이즈 팩터(용접광) 0%, 50%, 100%

용접광과 같은 강한 조명 노이즈가 추가되었을 때, 모델은 부재 간 경계와 용접 부위를 구분하는 데 어려움을 겪었다. 특히 조명 노이즈가 100%일 때는 용접광의 강렬한 반사로 인해 모델이 부재 간의 거리를 제대로 계산하지 못하고, 용접선을 잘못 인식하는 경우가 빈번하게 발생하였다.

4. 스크래치 노이즈 팩터 0%, 50%, 100%

스크래치 노이즈가 없는 매끄러운 표면에서는 모델이 높은 정확도로 용접 부위를 인식하였으나, 50%와 100%에서 스크래치가 증가함에 따라 모델이 텍스처 변화를

제대로 반영하지 못하고 인식률이 낮아졌다.

5. 부식 팩터 0%, 50%, 100%

부식이 없을 때는 인식률이 높았으나, 부식 팩터가 50% 이상 적용되면 모델이 부식된 부분을 부재 경계로 오인하여 경계를 제대로 파악하지 못하는 경우가 발생하였다. 이는 특히 용접 부위에 대한 인식에서 큰 혼란을 일으켰다.

6. 모든 이미지와 노이즈 적용

모든 노이즈가 혼합된 환경에서는 모델의 성능이 매우 저조했다. 모델이 부재 간 경계를 제대로 인식하지 못하였고, 용접 부위의 정확한 위치를 파악하는 데에도 어려움을 겪었다.

결론적으로, 실제 데이터가 제외되었을 때 모델의 성능은 크게 낮아졌고, 인식률 또한 기대에 미치지 못했다. 실제 데이터를 사용하지 않고, 가상 데이터만으로 학습한 모델은 현실적인 이미지 인식에서 낮은 성능을 보였다. 이를 통해, 실제 현장의 데이터를 포함한 학습이 모델 성능 향상에 필수적이라는 결론을 내릴 수 있었다.



그림 20. 실제 이미지를 포함한 경우 1



그림 21. 실제 이미지를 포함한 경우 2



그림 22. 모델링 이미지만 포함한 경우 1



그림 23. 모델링 이미지만 포함한 경우 2

4. 연구결과 분석 및 평가

이번 연구에서는 다양한 환경적 요인과 파라미터에 따른 YOLO 모델의 성능을 분석하고자 하였다. 실험을 통해, 텍스처 노이즈, 조명, 조명 노이즈, 스크래치, 부식과 같은 다양한 요소들이 모델의 성능에 큰 영향을 미친다는 사실을 확인할 수 있었다. 하지만, 모든 실험에서 실제 현장의 데이터를 제외한 상태에서는 모델이 용접 부위를 제대로 인식하지 못하거나, 부재 간의 경계를 정확히 파악하지 못했다.

각각의 파라미터가 적용된 시뮬레이션 환경에서는 모델이 고유의 한계를 보였다. 텍스처 노이즈와 조명 조건이 심화될수록 모델의 성능이 급격히 저하되었으며, 스크래치와 부식과 같은 노이즈는 모델이 부재와 용접 부위를 오인하게 했다. 특히, 실제 데이터를 제외하고 시뮬레이션 데이터를 사용하여 학습한 모델들은 모두 용접 부위의 정확한 길이와 위치를 예측하지 못했다.

또한, 모델은 용접선의 길이 예측을 시도하였으나, 실제 길이를 정확하게 계산하지 못했다. 다양한 파라미터를 반영한 시뮬레이션 데이터를 통해 학습된 모델은 경계를 명확히 구분하지 못하고, 부재 간의 거리나 용접선 길이를 예측하는 데에도 실패하였다. 이는 가상 데이터만으로는 현실적인 조건을 충분히 반영하지 못한다는 한계를 보여준다.

결론적으로, 다양한 시뮬레이션 환경에서 모델을 학습시키는 것은 중요하지만, 실제 현장 데이터를 결합하지 않는 한 정확한 용접 부위 인식과 길이 예측은 불가능하다는 결론에 도달하였다.

5. 결론 및 향후 연구 방향

본 연구에서는 다양한 조건과 변수 아래에서 YOLO 모델을 학습시키고, 이를 통해 용접 부위와 용접선의 길이를 예측하려는 시도를 진행하였다. 하지만, 실제 데이터를 제외한 시뮬레이션 환경에서는 모델의 성능이 크게 저하되었으며, 용접 부위의 인식 정확도와 길이 예측 모두 실패하는 결과를 낳았다.

이를 통해 얻은 중요한 교훈은, 단순히 가상 데이터를 통해 다양한 시나리오를 구성하는 것만으로는 현실적인 문제를 해결할 수 없다는 것이다. 실제 현장 데이터를 충분히 포함하고, 시뮬레이션 데이터와의 적절한 조화를 이루어야만 모델이 현실에서 발생할 수 있는 다양한 상황에 대처할 수 있다는 것을 알게 되었다.

향후 연구에서는 더욱 정밀한 3D 데이터와 함께 실제 데이터를 적극적으로 반영한 학습 방식을 도입할 필요가 있다. 또한, Depth 카메라와 같은 고급 센서를 사용하여 부재 간의 거리 및 용접선의 정확한 길이를 추출할 방법을 모색할 예정이다. 이를 통해 보다 정밀하고 현실적인 용접 부위 인식 및 길이 예측 모델을 개발하는 것이 목표이다.

6. 구성원별 역할 및 개발 일정

6.1 구성원별 역할

학 번	성 명	구성원별 역할
201924443	김주언	<ul style="list-style-type: none"> - 팀장으로 프로젝트 방향성을 제시하고 주도 - Unity 를 활용한 UI 개발 - Unity 3D 모델링 고도화를 위한 그림자 품질 개선 - 3D 모델링 작업 주도
201924461	류태욱	<ul style="list-style-type: none"> - 용접광 표현 위한 3D 오브젝트 개발 및 카메라 설정 - 다양한 Noise를 적용하기 위한 텍스처 및 map 개발 - 3D 모델링 작업
201924576	정재빈	<ul style="list-style-type: none"> - Unity 를 활용한 용접장 모델 자동 생성 프로그램 개발 - Masking 학습 데이터 자동 생성 프로그램 개발 - 3D 모델링 작업

6.2 개발 일정

일정	5월		6월				7월				8월				9월			
세부 항목	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4
선행 연구 분석 및 작수 보고서 작성																		
데이터 증강 방법 조사 및 Unity 3D 모델 개발																		
Unity 3D 모델, 시뮬레이터 개발, 중간 보고서 작성																		
YOLO 모델 학습 및 시뮬레이터 고도화																		
최종 보고서 작성 및 발표 준비																		

7. 참고문헌

- [1] Learn OpenGL [Online]. Available:
<https://learnopengl.com/Advanced-OpenGL/Stencil-testing>
- [2] Unity Scripting API Documentation [Online]. Available:
<https://docs.unity3d.com/ScriptReference/Shader.html>
- [3] Line Segment Detection Using Transformers without Edges
<https://arxiv.org/abs/2101.01909>
- [4] DeepLSD
<https://arxiv.org/abs/2212.07766>
- [5] 결함검출 적용을 위한 YOLO 딥러닝 알고리즘 비교
<http://journal.ksmte.kr/xml/31449/31449.pdf>
- [6] yolov8 공식문서
<https://docs.ultralytics.com/ko/models/yolov8/>